

Sistemas de Apoyo a la Decisión

Responsables: Matristes

Marcos Cobo Gutiérrez, Gabriel Gutiérrez Portal, Aritz de la Pinta Morales, Ibai Munné Ugalde



Mejor “Pipeline”

Preprocesado

Normalización Bilingüe (ES/EN)

Eliminación de stopwords
Preservando negaciones

Stemming y tokenización

Vectorización TF-IDF

Balanceo

Generativo (Ollama)

llama3:8b-text-q2_K
Técnica Few-Shot
Paráfrasis

Oversampling

Undersampling

None (ninguno)

Trucos adicionales

GridSearchCV

Combinaciones del clasificador

Evitar data leakage


Train / Dev

Class weights (balanced)

Logistic Regression

N-gramas (Vectorización)

PIPELINE GENERAL DE ANÁLISIS DE SENTIMIENTOS



Abstract Gráfico del Pipeline by Gemini

Resultados

Mejor modelo

Logistic Regression:

- Sin balanceo: 0.6334

- Balanceo:
Generativo + Oversampling

F1-macro en dev: 0.6334

	precision	recall	f1-score	support
negativo	0.74	0.69	0.71	1096
neutral	0.30	0.50	0.37	365
positivo	0.87	0.76	0.81	1539
accuracy			0.71	3000
macro avg	0.63	0.65	0.63	3000
weighted avg	0.75	0.71	0.72	3000

Resultados Logistic Regression sin balanceo

F1-macro en dev: 0.5945

	precision	recall	f1-score	support
negativo	0.69	0.65	0.67	1096
neutral	0.27	0.39	0.32	365
positivo	0.82	0.77	0.80	1539
accuracy			0.68	3000
macro avg	0.59	0.60	0.59	3000
weighted avg	0.71	0.68	0.69	3000

Resultados Logistic Regression con balanceo

Sin balanceo: F1 Macro

KNN: 0.3370

Naive Bayes: 0.6164

Decision Tree: 0.4815

Random Forest: 0.4363

Balanceo: F1 Macro

Generativo + Tradicional (Oversampling)


KNN: 0.3510

Naive Bayes: 0.5941


Decision Tree: 0.4642

Random Forest: 0.5641

Gráficos de codo



Calidad de temas - POSITIVAS



Calidad de temas - NEGATIVAS

Coherencia de los clusters

Coherence Score mide el sentido lógico de las palabras agrupadas.

Positivas: Mejor aproximación con 4 motivos de satisfacción diferenciados.

Negativas: Mejor aproximación de quejas se concentran de forma natural en 3 problemas principales.